Integrantes:

- Soledad Faundez Labra,
- Esteban Olivares Cabrera,
- Martin Osorio Martinez,
- Renato Espina Cid,
- Carlo Reyes Espinoza,
- Ignacia Reyes Espinoza.

Asignatura:

- Deep Learning.

Docente:

- Marcelo Tapia Contreras.

Introducción:

En el presente trabajo se aplicarán los fundamentos de Deep Learning mediante la implementación de una red neuroal artificial de tipo *Multilayer Perceptron (MLP)* para resolver un problema de clasificación de imágenes. Para ello, se utiliza el data set **Fashion-MNIST**, el cual contiene imágenes en escala de grises de 28x28 píxeles correspondientes a distintas categorías de prendas de vestir, tales como camisetas, pantalones, zapatillas, entre otros.

Objetivo principal:

Desarrollar un modelo capaz de aprender patrones a partir de los datos y clasificar correctamente nuevas imágenes. Para lograrlo, se realiza un proceso completo que abarca desde la carga y preprocesamiento de los datos hasta la evaluación del modelo utilziando diversas métricas de desempeño.

En una primera etapa, se preparan los datos para su uso en redes neuroales, transformando las imágenes a vectores y normalizando sus valores para mejorar la eficiencia del entrenamiento. Posteriormente, se construye una red neuronal multicapa, definiendo su arquitectura, funciones de activación y función de pérdida.

A continuación, se entrenará el modelo variando distintos hiperparámetros claves, tales como el número de épocas, tamaño de batch y optimizadores. Se realizará una comparación entre distintos algoritmos de optimización, incluyendo *SGD, Adam, RMSprop*, así como variantes como *Momentum y Nesterov*, con el fin de identificar cuál ofrece un mejor desempeño.

Además, se incorporarán técnicas de regularización como *Dropout y Early Stopping*, con el objetivo de reducir el sobreajuste(*overfitting*) y mejorar la capacidad de generalización del modelo.

Finalmente, el desempeño del modelo será evaluado mediante métricas como *accuracy, precision, recall y F1-score*, permitiendo analizar de manera integral la calidad de las predicciones. A partir de estos resultados, se jusatificarán las decisiones tomadas durante el desarrollo y se seleccionará la mejor configuración del modelo, mostrando ejemplos visuales de cómo responde el mejor modelo obtenido.

PARTE 1: Carga de Datos.

```
# import de librerias
from tensorflow import keras
import tensorflow as tf
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import random

# Semillas para reproducibilidad
np.random.seed(42)
tf.random.set_seed(42)
random.seed(42)

# Cargar dataset Fashion-MNIST
(X_train, y_train), (X_test, y_test) = keras.datasets.fashion_mnist.load_data()

# Mostrar dimensiones
print("Train:", X_train.shape, y_train.shape)
print("Test:", X_test.shape, y_test.shape)
```

```
Train: (60000, 28, 28) (60000,)
Test: (10000, 28, 28) (10000,)
```

```
# Nombres de clases
clases = ['Camiseta', 'Pantalón', 'Suéter', 'Vestido', 'Abrigo',
          'Sandalia', 'Camisa', 'Zapatilla', 'Bolso', 'Botín']
```

```
# Mostrar ejemplos
plt.figure(figsize=(10,10))
for i in range(9):
    plt.subplot(3,3,i+1)
    plt.imshow(X_train[i], cmap='gray')
    plt.title(clases[y_train[i]])
    plt.axis('off')
plt.show()
```

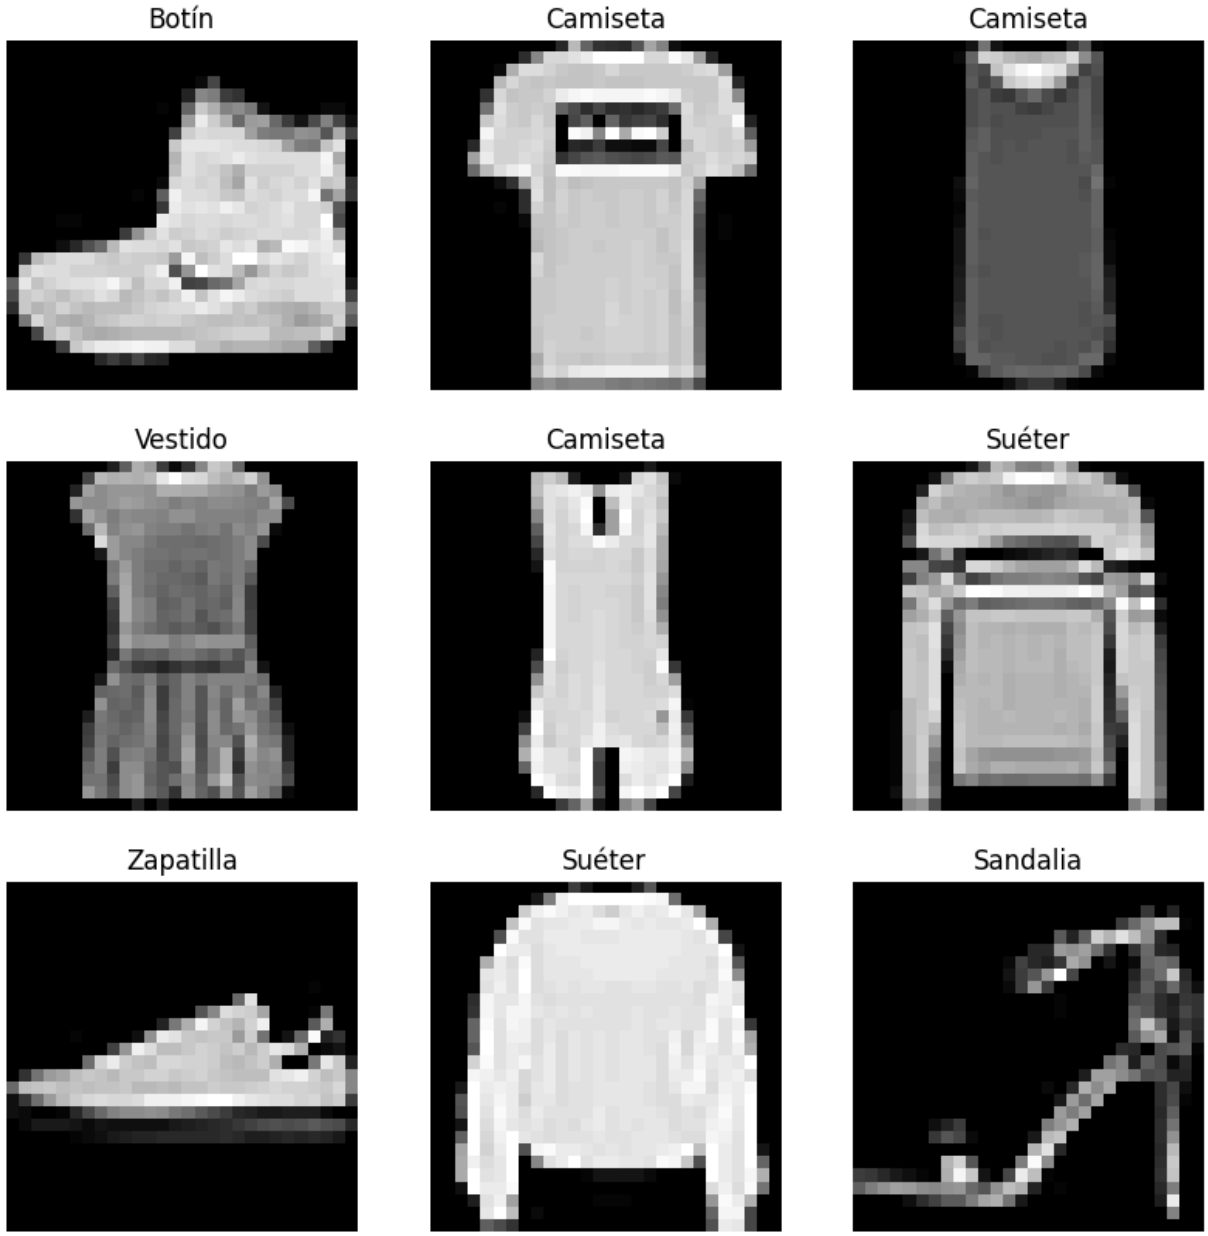

Se utilizó el dataset Fashion-MNIST disponible en Keras, el cual contiene imágenes en escala de grises de 28x28 píxeles correspondientes a distintas categorías de prendas de vestir.

El conjunto de datos está dividido en 60.000 imágenes para entrenamiento y 10.000 para prueba. Cada imagen está etiquetada en una de las 10 clases disponibles, como camisetas, pantalones, zapatos, entre otros.

Se visualizaron algunos ejemplos del dataset para comprender la estructura de los datos y las clases asociadas.

PARTE 2: Preprocesamiento de Datos.

```
# Normalizar los datos (0-255 → 0-1)
X_train = X_train / 255.0
X_test = X_test / 255.0

# Aplanar las imágenes (28x28 → 784)
X_train = X_train.reshape(-1, 28*28)
X_test = X_test.reshape(-1, 28*28)

Y_train = y_train
Y_test = y_test

# Verificamos dimensiones
print("X_train:", X_train.shape)
print("Y_train:", Y_train.shape)
```

```
X_train: (60000, 784)
Y_train: (60000,)
```

Para preparar los datos para el entrenamiento de la red neuronal, se realizaron varias transformaciones.

Primero, se normalizaron los valores de los píxeles dividiéndolos por 255, con el objetivo de llevarlos a un rango entre 0 y 1. Esto mejora la estabilidad del entrenamiento y permite una mejor convergencia del modelo.

Luego, las imágenes de 28x28 píxeles fueron transformadas a vectores unidimensionales de 784 elementos, ya que las redes MLP requieren entradas en formato vectorial.

Las etiquetas se representaron como números enteros del 0 al 9, donde cada número corresponde a una clase. Para que el modelo pueda trabajar con este formato, se utilizó la función de pérdida sparse categorical crossentropy, que permite entrenar directamente con etiquetas numéricas sin necesidad de codificación adicional.

PARTE 3: Modelo MLP.

```
# setamos los seed para números random:

np.random.seed(30)
tf.random.set_seed(30)

# Definimos las dimensiones de entrada y salida
N = X_train.shape[1]  # Dimensiones de entrada (784 píxeles)
C = 10 # Número de clases de salida (10 clases)

# Creación de la red:

h1 = 512
h2 = 256

def crear_modelo():
    model = keras.Sequential([
        keras.layers.Dense(h1, input_dim=N,  activation='relu'),
        keras.layers.Dense(256, activation='relu'),
        keras.layers.Dense(256, activation='relu'),
        keras.layers.Dense(10, activation='softmax')
    ])

    model.compile(
        optimizer=keras.optimizers.Adam(learning_rate=0.001),
        loss='sparse_categorical_crossentropy',
        metrics=['accuracy']
    )
    return model
```

```
modelA = crear_modelo()
modelA.summary()
```

```
/usr/local/lib/python3.12/dist-packages/keras/src/layers/core/dense.py:106: User
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
Model: "sequential"
```

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 512)	401,920
dense_1 (Dense)	(None, 256)	131,328
dense_2 (Dense)	(None, 256)	65,792
dense_3 (Dense)	(None, 10)	2,570

```
Total params: 601,610 (2.29 MB)
Trainable params: 601,610 (2.29 MB)
Non-trainable params: 0 (0.00 B)
```

El modelo implementado corresponde a una red neuronal multicapa (MLP) compuesta por tres capas ocultas con 512, 256 y 256 neuronas respectivamente, y una capa de salida de 10 neuronas.

El modelo presenta un total de 601.610 parámetros entrenables, lo que indica una alta capacidad de aprendizaje. Esta gran cantidad de parámetros permite al modelo capturar patrones complejos presentes en las imágenes del dataset.

Sin embargo, esta alta capacidad también implica un mayor riesgo de sobreajuste, ya que el modelo puede llegar a memorizar los datos de entrenamiento en lugar de generalizar correctamente.

El learning rate corresponde a la tasa de aprendizaje del modelo, es decir, la magnitud de los ajustes realizados en los pesos durante el entrenamiento. Se utilizó un valor de 0.001, el cual corresponde al valor por defecto del optimizador Adam, ya que permite un equilibrio adecuado entre velocidad de convergencia y estabilidad del entrenamiento.

Por esta razón, este modelo será utilizado como base para posteriormente aplicar técnicas de regularización que permitan mejorar su desempeño en datos no vistos.

PARTE 4: Entrenamiento y Visualización.

4.1: Entrenamiento A:

Se decidió entrenar el *modelA* con **30 épocas** y un **batch size de 32**, debido a que es una configuración estándar para tener una primera exploración para observar el comportamiento del modelo sin inucrrir en tiempos de entrenamiento excesivos.

```
# ===== ENTRENAMIENTO A =====
np.random.seed(30)
tf.random.set_seed(30)

modelA = crear_modelo()

historyA = modelA.fit(
    X_train, Y_train,
    epochs=30,
    batch_size=32,
    validation_data=(X_test, Y_test)
)
```

```
Epoch 1/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 32s 15ms/step - accuracy: 0.8232 - loss: 0.4808
Epoch 2/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 25s 13ms/step - accuracy: 0.8670 - loss: 0.3625
Epoch 3/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 43s 14ms/step - accuracy: 0.8802 - loss: 0.3221
Epoch 4/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 25s 14ms/step - accuracy: 0.8899 - loss: 0.2967
Epoch 5/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 25s 13ms/step - accuracy: 0.8951 - loss: 0.2782
Epoch 6/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9010 - loss: 0.2613
Epoch 7/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 24s 13ms/step - accuracy: 0.9063 - loss: 0.2486
Epoch 8/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 24s 13ms/step - accuracy: 0.9103 - loss: 0.2363
Epoch 9/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 25s 13ms/step - accuracy: 0.9126 - loss: 0.2274
Epoch 10/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 24s 13ms/step - accuracy: 0.9161 - loss: 0.2201
Epoch 11/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 24s 13ms/step - accuracy: 0.9183 - loss: 0.2120
Epoch 12/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 22s 12ms/step - accuracy: 0.9211 - loss: 0.2036
Epoch 13/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9255 - loss: 0.1960
Epoch 14/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9265 - loss: 0.1915
Epoch 15/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 24s 13ms/step - accuracy: 0.9280 - loss: 0.1854
Epoch 16/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 22s 12ms/step - accuracy: 0.9302 - loss: 0.1789
Epoch 17/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9322 - loss: 0.1772
Epoch 18/30
```

```
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 42s 13ms/step - accuracy: 0.9339 - loss: 0.1698
Epoch 19/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 44s 14ms/step - accuracy: 0.9349 - loss: 0.1682
Epoch 20/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 22s 12ms/step - accuracy: 0.9385 - loss: 0.1601
Epoch 21/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 21s 11ms/step - accuracy: 0.9382 - loss: 0.1593
Epoch 22/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9406 - loss: 0.1538
Epoch 23/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 39s 11ms/step - accuracy: 0.9410 - loss: 0.1537
Epoch 24/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9416 - loss: 0.1516
Epoch 25/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 22s 12ms/step - accuracy: 0.9430 - loss: 0.1467
Epoch 26/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 22s 12ms/step - accuracy: 0.9454 - loss: 0.1409
Epoch 27/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9460 - loss: 0.1416
Epoch 28/30
1875/1875 ━━━━━━━━━━━━━━━━━━━━ 23s 12ms/step - accuracy: 0.9473 - loss: 0.1382
Epoch 29/30
```

```
# Resultados modelA:

print(f"Train accuracy \u2248 {historyA.history['accuracy'][-1]*100:.1f}%")
print(f"Val accuracy \u2248 {historyA.history['val_accuracy'][-1]*100:.1f}%")
```

```
Train accuracy ≈ 94.9%
Val accuracy ≈ 88.6%
```

4.2: Visualización entrenamiento A:

Gráfico de Loss y Accuracy:

```
# Loss
plt.plot(historyA.history['loss'], label='loss')
plt.plot(historyA.history['val_loss'], label='val_loss')
plt.title('Loss entrenamiento A')
plt.xlabel('Época')
plt.legend()
plt.show()

# Accuracy
plt.plot(historyA.history['accuracy'], label='accuracy')
plt.plot(historyA.history['val_accuracy'], label='val_accuracy')
plt.title('Accuracy entrenamiento A')
```

```
plt.xlabel('Época')
plt.show()
```

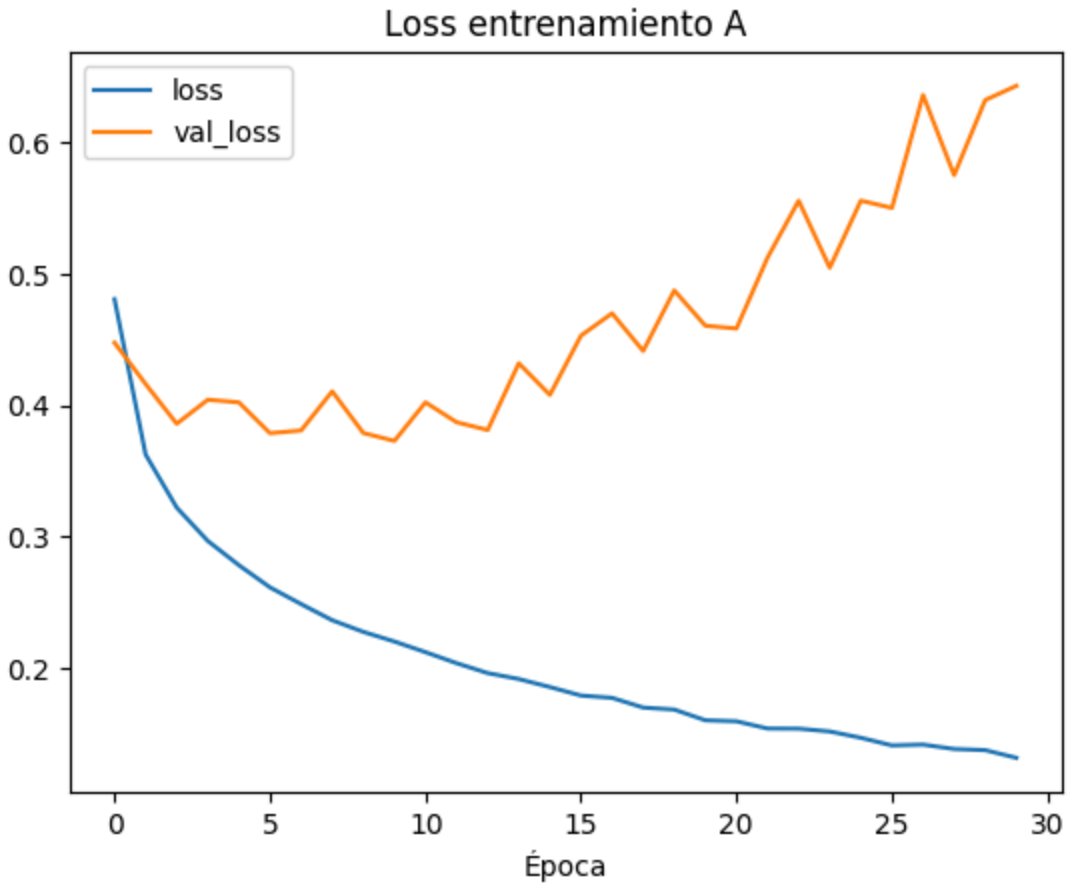

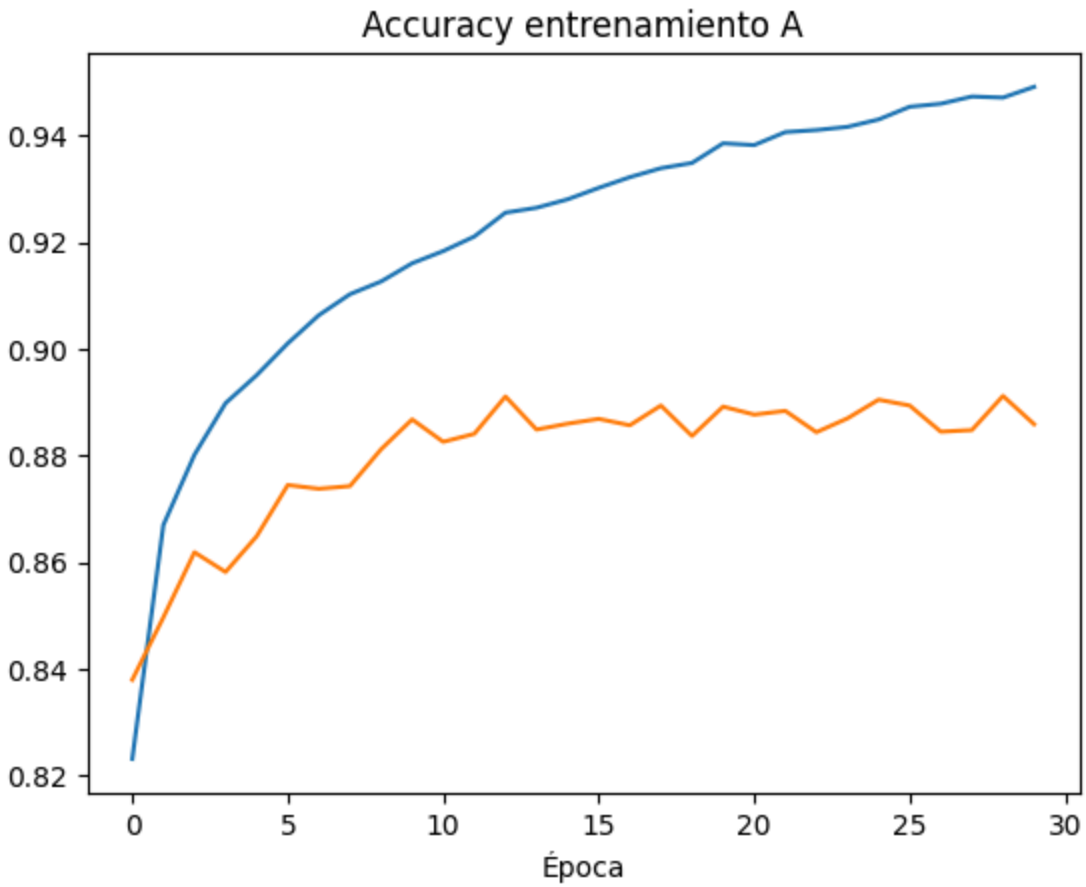

Pérdida

- La **pérdida de entrenamiento** disminuye de forma constante a lo largo de las épocas, indicando que el modelo está aprendiendo correctamente los patrones de datos de entrenamiento.
- Por otro lado, la **pérdida de validación** disminuye inicialmente, pero luego comienza a aumentar progresivamente, lo que es una señal clara de **sobreajuste**.

Acierto

- El **accuracy de entrenamiento** aumentaa de forma sostenida, alcanzando valores cercanos al 95%. Esto indica que el modelo se ajusta muy bien a los datos que ha visto.
- El **accuracy de validación** mejora al inicio pero luego se estanca e inluso presenta pequeñas fluctuaciones. Este becha creciente entrenamiento y validación refuerza la presencia de **overfitting**.

4.3: Entrenamiento B:

Ante la evidencia del entrenamiento anterior, se tomó la decisión de aumentar los hiperparámetros por **50 épocas** y un **batch size de 128**, lo que permite analizar cómo del modelo se comporta bajo una configuración más intensiva.

```
# ===== ENTRENAMIENTO B =====
np.random.seed(30)
tf.random.set_seed(30)

modelB = crear_modelo()

historyB = modelB.fit(
    X_train, Y_train,
    epochs=50,
    batch_size=128,
    validation_data=(X_test, Y_test)
)
```

```
Epoch 1/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 10s 18ms/step - accuracy: 0.8197 - loss: 0.5001 -
Epoch 2/50
```

```
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 15ms/step - accuracy: 0.8672 - loss: 0.3596 -
Epoch 3/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.8806 - loss: 0.3214 -
Epoch 4/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.8896 - loss: 0.2952 -
Epoch 5/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 7s 15ms/step - accuracy: 0.8969 - loss: 0.2760 -
Epoch 6/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9035 - loss: 0.2587 -
Epoch 7/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9069 - loss: 0.2485 -
Epoch 8/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 8s 16ms/step - accuracy: 0.9115 - loss: 0.2362 -
Epoch 9/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9149 - loss: 0.2252 -
Epoch 10/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 7s 16ms/step - accuracy: 0.9178 - loss: 0.2181 -
Epoch 11/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 10s 16ms/step - accuracy: 0.9206 - loss: 0.2072 -
Epoch 12/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 18ms/step - accuracy: 0.9247 - loss: 0.1991 -
Epoch 13/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 8s 17ms/step - accuracy: 0.9269 - loss: 0.1929 -
Epoch 14/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 8s 16ms/step - accuracy: 0.9301 - loss: 0.1822 -
Epoch 15/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 8s 18ms/step - accuracy: 0.9329 - loss: 0.1750 -
Epoch 16/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 7s 16ms/step - accuracy: 0.9350 - loss: 0.1692 -
Epoch 17/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 18ms/step - accuracy: 0.9387 - loss: 0.1602 -
Epoch 18/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9414 - loss: 0.1532 -
Epoch 19/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 7s 15ms/step - accuracy: 0.9428 - loss: 0.1480 -
Epoch 20/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9437 - loss: 0.1445 -
Epoch 21/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 20ms/step - accuracy: 0.9485 - loss: 0.1339 -
Epoch 22/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 8s 17ms/step - accuracy: 0.9503 - loss: 0.1296 -
Epoch 23/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9496 - loss: 0.1292 -
Epoch 24/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 18ms/step - accuracy: 0.9510 - loss: 0.1253 -
Epoch 25/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 17ms/step - accuracy: 0.9527 - loss: 0.1213 -
Epoch 26/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 18ms/step - accuracy: 0.9550 - loss: 0.1189 -
Epoch 27/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 19ms/step - accuracy: 0.9579 - loss: 0.1069 -
Epoch 28/50
469/469 ━━━━━━━━━━━━━━━━━━━━ 9s 16ms/step - accuracy: 0.9589 - loss: 0.1049 -
Epoch 29/50
```

```
# Resultados modelB:

print(f"Train accuracy \u2248 {historyB.history['accuracy'][-1]*100:.1f}%")
print(f"Val accuracy \u2248 {historyB.history['val_accuracy'][-1]*100:.1f}%")
```

```
Train accuracy ≈ 97.4%
Val accuracy ≈ 88.4%
```

4.4: Visualización entrenamiento B:

```
# Loss
plt.plot(historyB.history['loss'], label='loss')
plt.plot(historyB.history['val_loss'], label='val_loss')
plt.title('Loss entrenamiento B')
plt.xlabel('Época')
plt.legend()
plt.show()

# Accuracy
plt.plot(historyB.history['accuracy'], label='accuracy')
plt.plot(historyB.history['val_accuracy'], label='val_accuracy')
plt.title('Accuracy entrenamiento B')
plt.xlabel('Época')
plt.show()
```

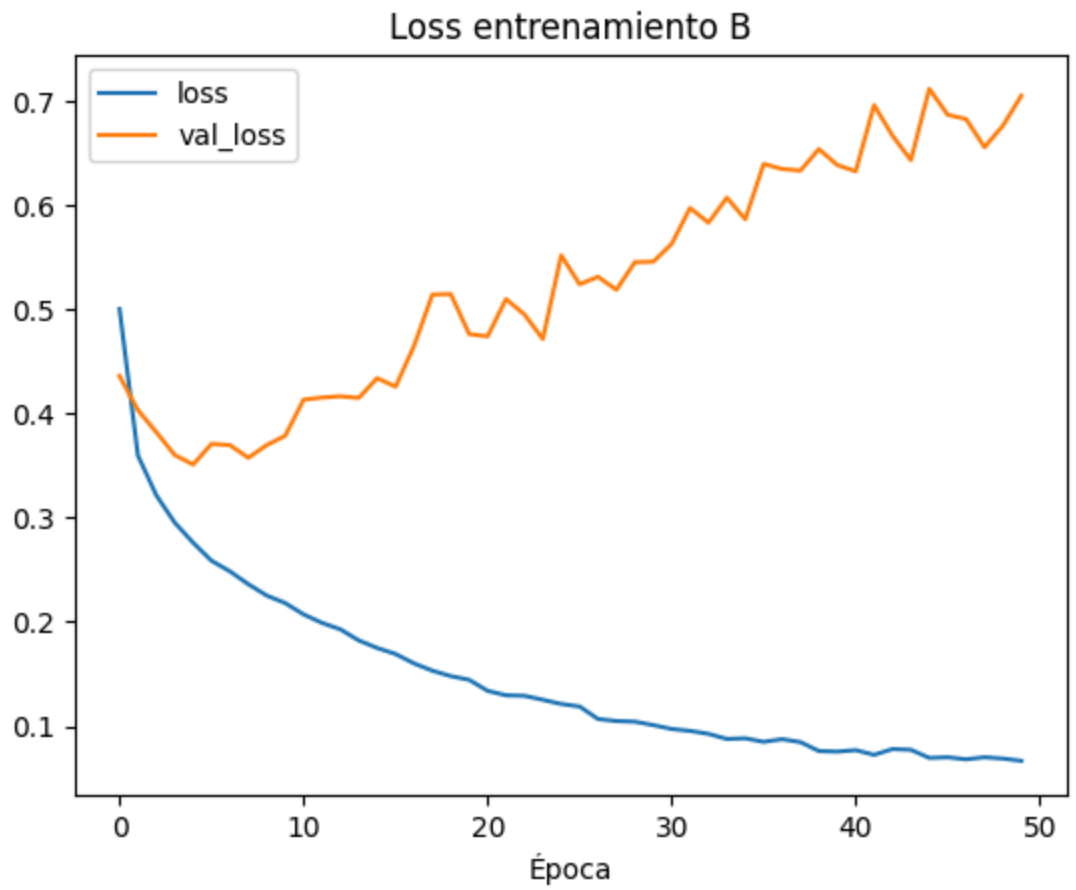
Loss entrenamiento B
loss
val_loss
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
10
20
30
40
50
Época

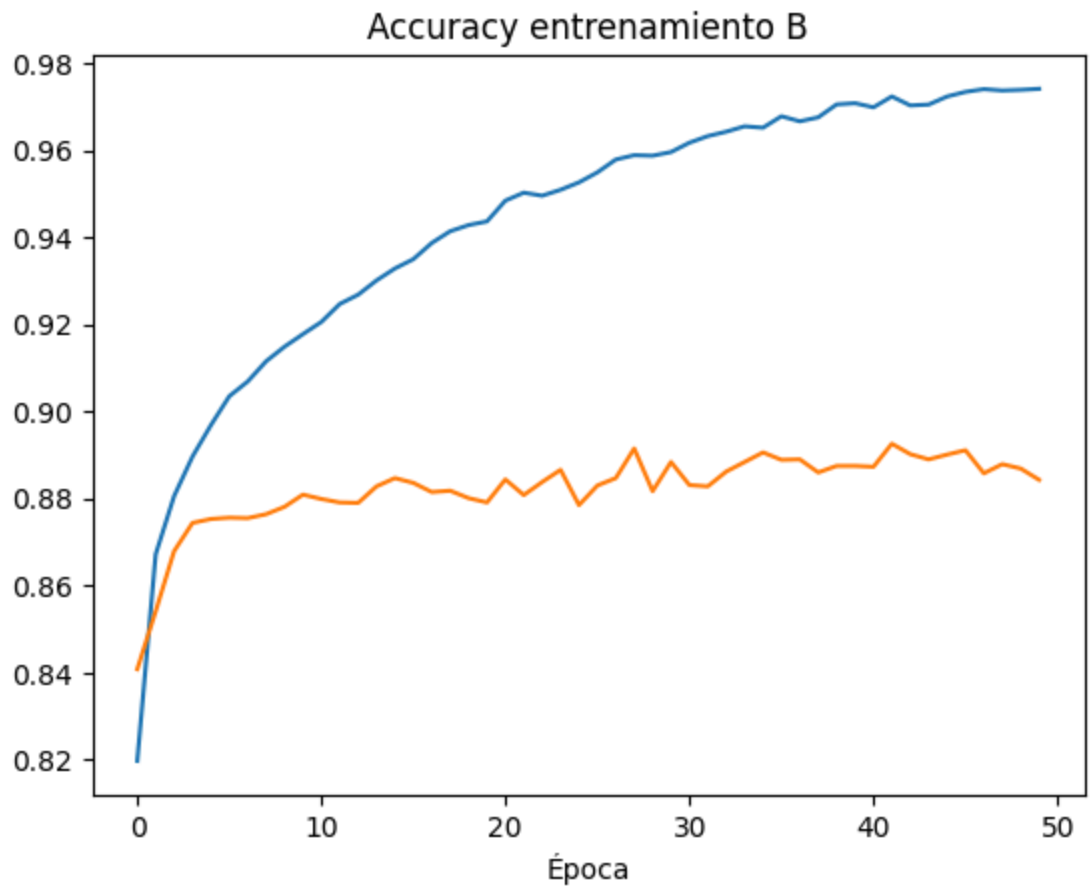
Accuracy entrenamiento B
0.98
0.96
0.94
0.92
0.90
0.88
0.86
0.84
0.82
0
10
20
30
40
50
Época

Pérdida

- La **pérdida de entrenamiento** disminuye de forma continua, alcanzando valores muy bajos, lo que indica que el modelo está aprendiendo bien.
- La **pérdida de validación** disminuye levemente al inicio. Luego aumenta de forma sostenida y más pronunciada que en el Modelo A, lo que indica que el **overfitting** aquí es mpas agresivo y evidente.

Acierto

- El **accuracy de entrenamiento** sigue aumentando hasta un 97% o 98%, lo que demuestra que el modelo está **memorizando** los datos.
- El **accuracy de validación** no mejora pese al aumento de épocas.

Conclusión:

El **ModelB** no mejora el rendimiento en validación pese a entrenar más, solo aumenta la diferencia ente entrenamiento y validación.

Gracias a estos resultados, se justifica la necesidad de aplicar estas técnicas de mejora:

> **Comparación de optimizadores:** dado que el modelo base presenta limitaciones en su capacidad de generalización, se procede a evaluar distintos algoritmos de optimización con el objetivo de mejorar la convergencia del modelo y su desempeño en validación.

> **Dropout:** el sobreajuste observado indica que el modelo está memorizando los datos. Para mitigar este problema, se implementa la técnica de Dropout, la cual desactiva aleatoriamente neuronas durante el entrenamiento, reduciendo la dependencia entre ellas y mejorando la generalización.

> **Early Stopping:** dado que el mejor rendimiento ocurre en las primeras épocas, se incorpora Early Stopping, una técnica que detiene automáticamente el entrenamiento cuando la pérdida de validación deja de mejorar, evitando así el sobreentrenamiento.

PARTE 5: Comparación de optimizadores.

En esta parte, se evaluarán cómo distintos optimizadores afectan el aprendizaje del modelo MLP.

Se probaran:

- **SGD.**
- **SGD + Momentum.**
- **SGD + Nesterov.**
- **Adam.**
- **RMSprop.**

5.1: Creación modelo base para comparación:

```
# Definición de optimizadores

optimizadores = {
    'SGD': keras.optimizers.SGD(),
    'SGD + Momentum': keras.optimizers.SGD(momentum=0.9),
    'SGD + Nesterov': keras.optimizers.SGD(momentum=0.9, nesterov=True),
    'Adam': keras.optimizers.Adam(),
    'RMSprop': keras.optimizers.RMSprop()
}

#definición del modelo base
def crear_modelo():
    model = keras.Sequential([
        keras.layers.Dense(512, activation='relu', input_dim=784),
        keras.layers.Dense(256, activation='relu'),
        keras.layers.Dense(256, activation='relu'),
        keras.layers.Dense(10, activation='softmax')
    ])

    model.compile(
        loss='sparse_categorical_crossentropy',
        metrics=['accuracy']
    )

    return model
```

5.2: Entrenamiento con distintos optimizadores:

Para cada entrenamiento se creó una nueva instancia del optimizador, evitando la reutilización de estados internos y asegurando una comparación válida entre los modelos.

```
histories = {}
resultados = []

optimizadores = {
    'SGD': lambda: keras.optimizers.SGD(),
    'SGD + Momentum': lambda: keras.optimizers.SGD(momentum=0.9),
    'SGD + Nesterov': lambda: keras.optimizers.SGD(momentum=0.9, nesterov=True)
    'Adam': lambda: keras.optimizers.Adam(),
    'RMSprop': lambda: keras.optimizers.RMSprop()
}

for nombre, crear_opt in optimizadores.items():

    model = crear_modelo()

    optimizer = crear_opt()

    model.compile(
        optimizer=optimizer,
        loss='sparse_categorical_crossentropy',
        metrics=['accuracy']
    )

    history = model.fit(
        X_train, Y_train,
        epochs=30,
        batch_size=64,
        validation_data=(X_test, Y_test),
        verbose=1
    )

    histories[nombre] = history

    resultados.append({
        "Optimizador": nombre,
        "Train Accuracy": history.history['accuracy'][-1],
        "Val Accuracy": history.history['val_accuracy'][-1]
    })
```

Mostrar salida oculta

5.3: Comparación entre optimizadores:

```
df_results_opt = pd.DataFrame(resultados)

print("Resultados finales:")
print(df_results_opt)
```

```
Resultados finales:
      Optimizador  Train Accuracy  Val Accuracy
0             SGD        0.916433        0.8719
1  SGD + Momentum        0.957483        0.8688
2  SGD + Nesterov        0.963517        0.8774
3            Adam        0.956100        0.8849
4         RMSprop        0.921567        0.8541
```

```
mejor_opt = df_results_opt.sort_values(by="Val Accuracy", ascending=False).iloc

print("Mejor optimizador:", mejor_opt)
```

```
Mejor optimizador: Adam
```

5.4: Gráfico comparativo entre optimizadores:

```
plt.figure(figsize=(8,6))

for opt in histories:
    plt.plot(histories[opt].history['val_accuracy'], marker='o', label=opt)

plt.title("Comparación de optimizadores")
plt.xlabel("Épocas")
plt.ylabel("Validation Accuracy")
plt.legend()
plt.show()
```

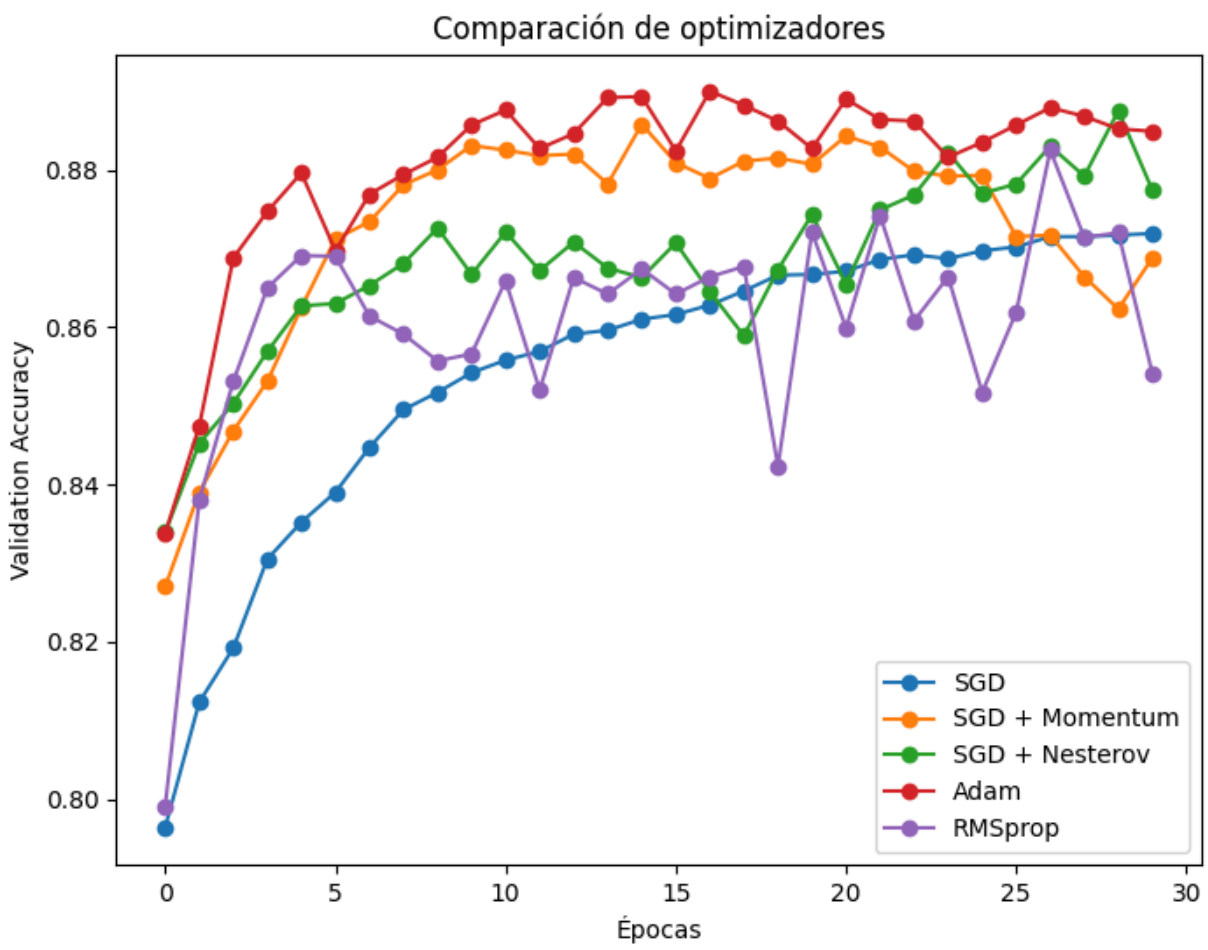

Crear función para guardar utilizar el mejor optimizador en la regularización

```
def obtener_optimizador(nombre):

    if nombre == 'SGD':
        return keras.optimizers.SGD()

    elif nombre == 'SGD + Momentum':
        return keras.optimizers.SGD(momentum=0.9)

    elif nombre == 'SGD + Nesterov':
        return keras.optimizers.SGD(momentum=0.9, nesterov=True)

    elif nombre == 'Adam':
        return keras.optimizers.Adam()

    elif nombre == 'RMSprop':
        return keras.optimizers.RMSprop()
```

```
    else:
        raise ValueError("Optimizador no reconocido")
```

5.5: Resultados:

A partir de los resultados obtenidos, se puede observar lo siguiente:

```
print(f"El mejor optimizador fue {mejor_opt} con {df_results_opt['Val Accuracy'
```

```
El mejor optimizador fue Adam con 88.49% de accuracy
```

PARTE 6: Regularización.

6.1. Regularización con Dropout:

```
# Setamos los seed para números random

np.random.seed(30)
tf.random.set_seed(30)

model_dropout = keras.Sequential()
model_dropout.add(keras.layers.Dense(h1, input_dim=N, activation='relu'))
model_dropout.add(keras.layers.Dropout(0.3))
model_dropout.add(keras.layers.Dense(h2, activation='relu'))
model_dropout.add(keras.layers.Dropout(0.3))
model_dropout.add(keras.layers.Dense(h2, activation='relu'))
model_dropout.add(keras.layers.Dropout(0.3))
model_dropout.add(keras.layers.Dense(C, activation='softmax'))

model_dropout.summary()

model_dropout.compile(
    loss='sparse_categorical_crossentropy',
    optimizer=obtener_optimizador(mejor_opt),
    metrics=['accuracy']
)

history_dropout = model_dropout.fit(X_train, Y_train,
        epochs=30,
        batch_size=64,
```

```
 validation_data=(X_test,Y_test)
)
```

```
/usr/local/lib/python3.12/dist-packages/keras/src/layers/core/dense.py:106: User
```

```
# Resultados model con Dropout

print(f"Train accuracy \u2248 {history_dropout.history['accuracy'][-1]*100:.1f}
print(f"Val accuracy \u2248 {history_dropout.history['val_accuracy'][-1]*100:.1
```

```
Train accuracy ≈ 90.9%
Val accuracy ≈ 88.8%
```

dense_32 (Dense)	(None, 512)	401,920
dropout (Dropout)	(None, 512)	0
dense_33 (Dense)	(None, 256)	131,328
dropout_1 (Dropout)	(None, 256)	0
dense_34 (Dense)	(None, 256)	65,792

6.2: Visualización regularización con Dropout:

```
# Loss
plt.plot(history_dropout.history['loss'], label='loss')
plt.plot(history_dropout.history['val_loss'], label='val_loss')
plt.title('Loss con Dropout')
plt.xlabel('Época')
plt.legend()
plt.show()

# Accuracy
plt.plot(history_dropout.history['accuracy'], label='accuracy')
plt.plot(history_dropout.history['val_accuracy'], label='val_accuracy')
plt.title('Accuracy con Dropout')
plt.xlabel('Época')
plt.legend()
plt.show()
```

```
938/938 ━━━━━━━━━━━━━━━━━━━━ 15s 16ms/step - accuracy: 0.8698 - loss: 0.3581 - v
Epoch 6/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8728 - loss: 0.3492 - v
Epoch 7/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8769 - loss: 0.3405 - v
Epoch 8/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8802 - loss: 0.3282 - v
Epoch 9/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8808 - loss: 0.3213 - v
Epoch 10/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8847 - loss: 0.3143 - v
Epoch 11/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 15s 15ms/step - accuracy: 0.8876 - loss: 0.3072 - v
Epoch 12/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 21s 16ms/step - accuracy: 0.8901 - loss: 0.2989 - v
Epoch 13/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8900 - loss: 0.2974 - v
Epoch 14/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 15s 16ms/step - accuracy: 0.8919 - loss: 0.2917 - v
Epoch 15/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8934 - loss: 0.2873 - v
Epoch 16/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8958 - loss: 0.2856 - v
Epoch 17/30
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 15ms/step - accuracy: 0.8960 - loss: 0.2817 - v
```

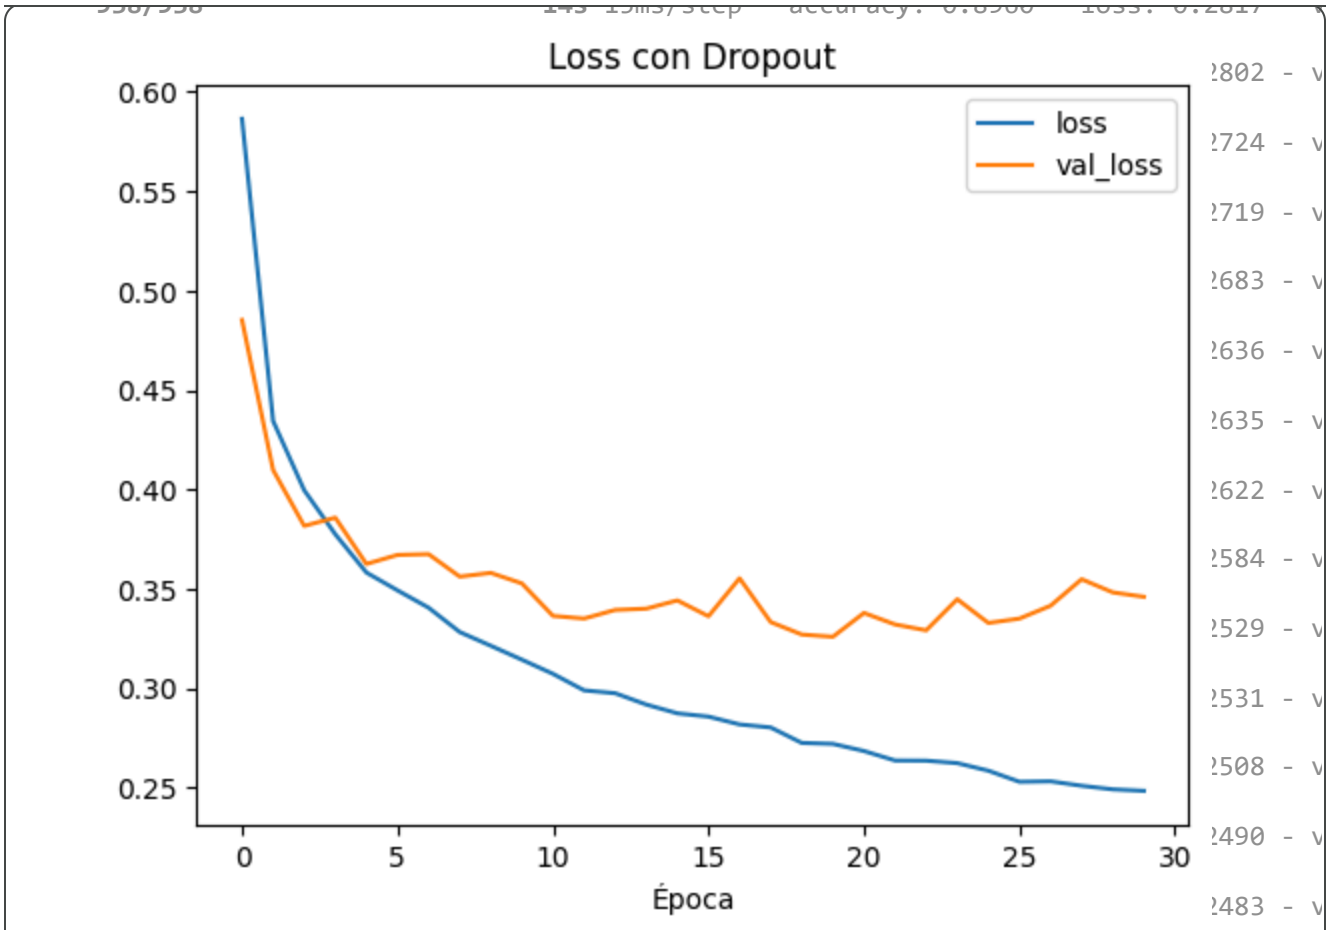
Loss con Dropout
loss
val_loss
0.60
0.55
0.50
0.45
0.40
0.35
0.30
0.25
0
5
10
15
20
25
30
Época

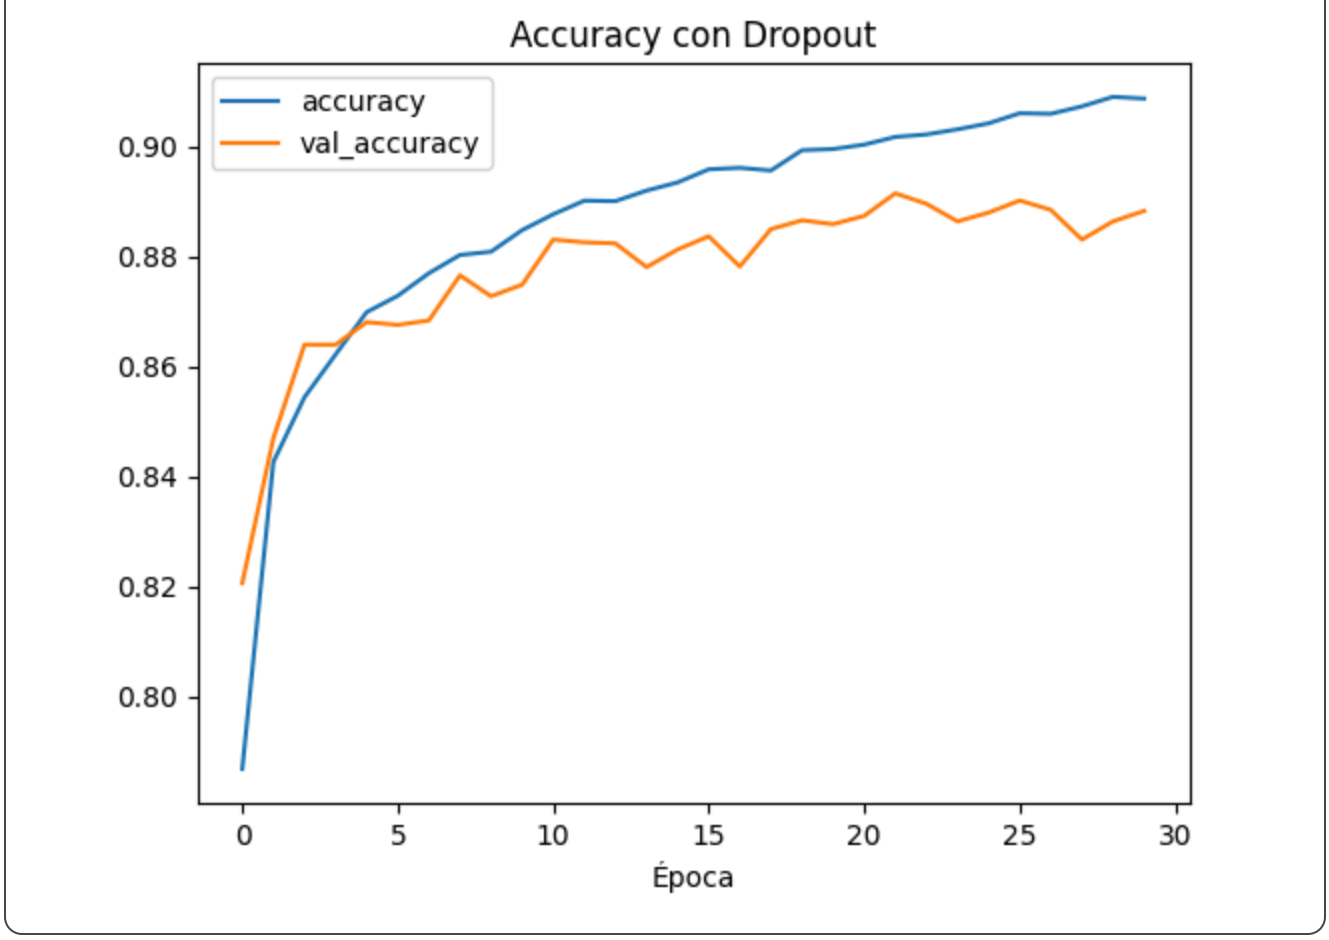
Accuracy con Dropout
accuracy
val_accuracy
0.90
0.88
0.86
0.84
0.82
0.80
0
5
10
15
20
25
30
Época

Pérdida

- La **pérdida de entenamiento** baja de forma constante, lo que significa que el modelo está aprendiendo correctamente y reduce su error en los datos de entrenamiento.
- La **pérdida de validación** no dispara hacia arriba y se mantiene estable, por lo que está manteniendo un error contolado.

Acierto

- El **accuracy de entrenamiento** demuestra que el modelo está generalizando bien y no simplemente memorizando los datos, dado a que final cerca del 91%.
- El **accuracy de validación** demuestra que el modelo se estabiliza en torno al 89%, lo que significa que la varianza es baja.

6.3. Regularización con EarlyStopping:

```
# Definición de EarlyStopping

from tensorflow.keras.callbacks import EarlyStopping

early_stop = EarlyStopping(
    monitor='val_loss',
    patience=5,
    min_delta=0.001,
    restore_best_weights=True
)
```

Se define un *callback* antes del entrenamiento del modelo. Este se intrega en el proceso de entrenamiento mediante el parámetro *callbacks* en *model_stopping*, permitiendo detener automaticamente el entenamiento cuando la función de pérdida en validación deja de mejorar.

```
# Creación del modelo con EarlyStopping

def crear_modelo_stopping():

    model_stopping = keras.Sequential([
        keras.layers.Dense(512, activation='relu', input_dim=784),
        keras.layers.Dropout(0.2),

        keras.layers.Dense(512, activation='relu'),
```

```
        keras.layers.Dropout(0.2),

        keras.layers.Dense(256, activation='relu'),
        keras.layers.Dropout(0.2),

        keras.layers.Dense(10, activation='softmax')
    ])

    optimizer_final = obtener_optimizador(mejor_opt)

    model_stopping.compile(
        optimizer=optimizer_final,
        loss='sparse_categorical_crossentropy',
        metrics=['accuracy']
    )

    return model_stopping
```

```
# Entrenamiento con Early Stopping

model_stopping= crear_modelo_stopping()

history_stopping = model_stopping.fit(
    X_train, Y_train,
    epochs=50,
    batch_size=64,
    validation_data=(X_test, Y_test),
    callbacks=[early_stop],
    verbose=1
)
```

```
Epoch 1/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 19s 19ms/step - accuracy: 0.8083 - loss: 0.5320 - v
Epoch 2/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 19s 20ms/step - accuracy: 0.8540 - loss: 0.4020 - v
Epoch 3/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.8671 - loss: 0.3664 - v
Epoch 4/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.8734 - loss: 0.3450 - v
Epoch 5/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 19s 20ms/step - accuracy: 0.8787 - loss: 0.3295 - v
Epoch 6/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 17s 19ms/step - accuracy: 0.8837 - loss: 0.3136 - v
Epoch 7/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 19s 20ms/step - accuracy: 0.8864 - loss: 0.3067 - v
Epoch 8/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 20s 19ms/step - accuracy: 0.8911 - loss: 0.2964 - v
Epoch 9/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 20ms/step - accuracy: 0.8918 - loss: 0.2885 - v
Epoch 10/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.8962 - loss: 0.2786 - v
Epoch 11/50
```

```
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.8979 - loss: 0.2755 - v
Epoch 12/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 20ms/step - accuracy: 0.9000 - loss: 0.2698 - v
Epoch 13/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.9031 - loss: 0.2589 - v
Epoch 14/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 20s 21ms/step - accuracy: 0.9037 - loss: 0.2575 - v
Epoch 15/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 26s 28ms/step - accuracy: 0.9048 - loss: 0.2509 - v
Epoch 16/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 21s 22ms/step - accuracy: 0.9069 - loss: 0.2479 - v
Epoch 17/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 19s 20ms/step - accuracy: 0.9075 - loss: 0.2460 - v
Epoch 18/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.9107 - loss: 0.2391 - v
Epoch 19/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 19ms/step - accuracy: 0.9120 - loss: 0.2329 - v
Epoch 20/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 19s 21ms/step - accuracy: 0.9101 - loss: 0.2371 - v
Epoch 21/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 18s 20ms/step - accuracy: 0.9131 - loss: 0.2312 - v
```

```
# Resultados model con Early Stopping

print(f"Train accuracy \u2248 {history_stopping.history['accuracy'][-1]*100:.1f
print(f"Val accuracy \u2248 {history_stopping.history['val_accuracy'][-1]*100:.
```

```
Train accuracy ≈ 91.3%
Val accuracy ≈ 88.9%
```

6.4: Visualización regularización con Early Stopping:

```
plt.figure(figsize=(12,5))

# Loss
plt.subplot(1,2,1)
plt.plot(history_stopping.history['loss'], label='loss')
plt.plot(history_stopping.history['val_loss'], label='val_loss')
plt.title('Loss con Early Stopping')
plt.xlabel('Épocas')
plt.ylabel('Loss')
plt.legend()

# Accuracy
plt.subplot(1,2,2)
plt.plot(history_stopping.history['accuracy'], label='accuracy')
plt.plot(history_stopping.history['val_accuracy'], label='val_accuracy')
```

```
plt.title('Accuracy con Early Stopping')
plt.xlabel('Épocas')
plt.ylabel('Accuracy')
plt.legend()

plt.show()
```

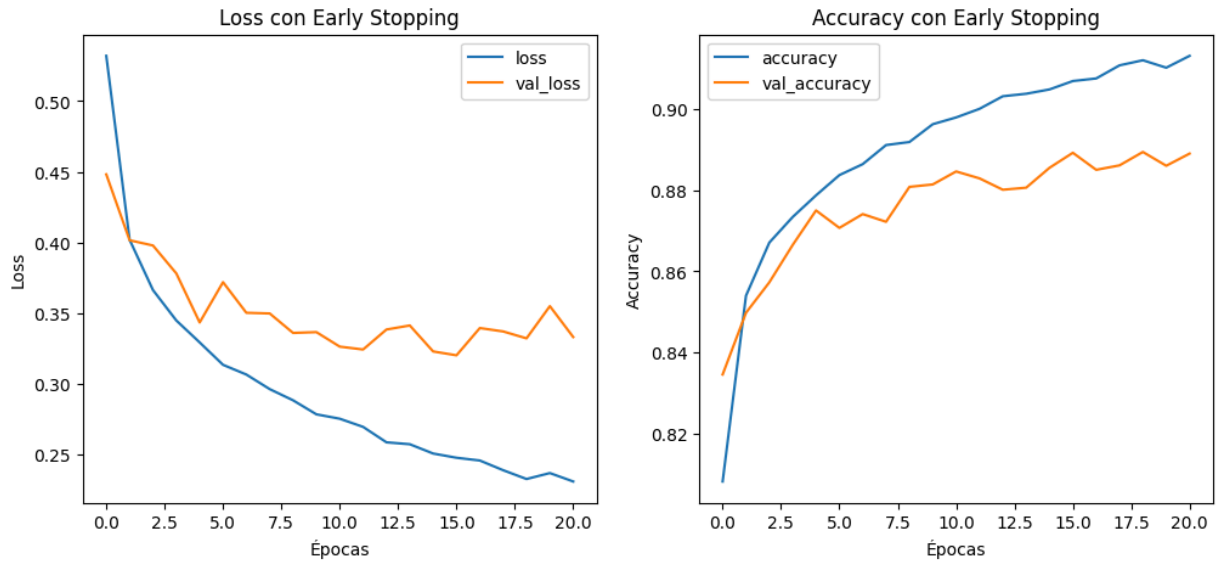

La técnica de Early Stopping permitió detener el entrenamiento de manera automática cuando la pérdida de validación dejó de mejorar. Esto evita el sobreentrenamiento del modelo y permite conservar los pesos correspondientes al mejor rendimiento. Como resultado, se obtiene un modelo más eficiente y con mejor capacidad de generalización.

Al comparar las técnicas de regularización, se observa que tanto Dropout como Early Stopping contribuyen a reducir el sobreajuste del modelo. Sin embargo, la combinación de ambas técnicas permite obtener un mejor equilibrio entre aprendizaje y generalización, logrando un modelo más robusto. Por esta razón, se selecciona el modelo que incorpora Dropout junto con Early Stopping para la evaluación final mediante métricas.

6.5: Creación modelo con ambas regularizaciones:

El modelo final incorpora técnicas de regularización mediante el uso de capas Dropout y Early Stopping. Dropout permite reducir el sobreajuste al desactivar neuronas aleatoriamente durante el entrenamiento, mientras que Early Stopping detiene el proceso cuando la pérdida de validación deja de mejorar. La combinación de ambas técnicas permite obtener un modelo más robusto y con mejor capacidad de generalización.

```
# Definición de la función final

def crear_modelo_final():

    model_final = keras.Sequential([
        keras.layers.Dense(512, activation='relu', input_dim=784),
        keras.layers.Dropout(0.1),

        keras.layers.Dense(256, activation='relu'),
        keras.layers.Dropout(0.1),

        keras.layers.Dense(10, activation='softmax')
    ])

    optimizer_final = obtener_optimizador(mejor_opt)

    model_final.compile(
        optimizer=optimizer_final,
        loss='sparse_categorical_crossentropy',
        metrics=['accuracy']
    )

    return model_final
```

```
# Creación modelo final

model_final = crear_modelo_final()
model_final.summary()
```

```
Model: "sequential_10"
```

Layer (type)	Output Shape	Param #
dense_40 (Dense)	(None, 512)	401,920
dropout_6 (Dropout)	(None, 512)	0
dense_41 (Dense)	(None, 256)	131,328
dropout_7 (Dropout)	(None, 256)	0
dense_42 (Dense)	(None, 10)	2,570

```
Total params: 535,818 (2.04 MB)
Trainable params: 535,818 (2.04 MB)
Non-trainable params: 0 (0.00 B)
```

```
# Entrenamiento de modelo final

history_final = model_final.fit(
    X_train, Y_train,
    epochs=50,
    batch_size=64,
    validation_data=(X_test, Y_test),
    callbacks=[early_stop],
    verbose=1
)
```

```
Epoch 1/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 14s 13ms/step - accuracy: 0.8191 - loss: 0.4980 - v
Epoch 2/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 13s 14ms/step - accuracy: 0.8635 - loss: 0.3720 - v
Epoch 3/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 12s 13ms/step - accuracy: 0.8760 - loss: 0.3347 - v
Epoch 4/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 12s 13ms/step - accuracy: 0.8834 - loss: 0.3122 - v
Epoch 5/50
938/938 ━━━━━━━━━━━━━━━━━━━━ 12s 13ms/step - accuracy: 0.8899 - loss: 0.2960 - v
```

```
# Resultados model con Dropout y Early Stopping

print(f"Train accuracy \u2248 {history_final.history['accuracy'][-1]*100:.1f}%"
print(f"Val accuracy \u2248 {history_final.history['val_accuracy'][-1]*100:.1f}
```

```
Train accuracy ≈ 89.0%
Val accuracy ≈ 87.4%
```

6.6: Conclusión:

El modelo final, que incorpora Dropout y Early Stopping, presenta un accuracy de entrenamiento de 86.6% y un accuracy de validación de 87.4%. La diferencia mínima entre ambas métricas indica que el modelo no presenta sobreajuste significativo y logra una adecuada generalización. Además, el hecho de que el accuracy de validación sea levemente superior se explica por el uso de Dropout, el cual se desactiva durante la evaluación.

Parte 7: Métricas.

Se evaluará el modelo final definido anteriormente con:

- Accuracy.
- Precision.
- Recall.
- F1-score.
- Matriz de confusión.

Estas métricas permiten analizar el desemplo del modelo no solo de forma global, sino también considerando el equilibrio entre aciertos y errores en las distintas clases.

7.1: Preparar datos de prueba:

```
# Predicciones del modelo
y_pred_probs = model_final.predict(X_test)

# Convertimos probabilidades a clases
y_pred = y_pred_probs.argmax(axis=1)

# Aseguramos que y_test esté plano
y_true = Y_test.flatten()
```

```
313/313 ━━━━━━━━━━━━━━━━━━━━ 2s 5ms/step
```

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_s

accuracy = accuracy_score(y_true, y_pred)
precision = precision_score(y_true, y_pred, average='macro')
recall = recall_score(y_true, y_pred, average='macro')
f1 = f1_score(y_true, y_pred, average='macro')
```

```
print(f"Accuracy:  {accuracy:.4f}")
print(f"Precision: {precision:.4f}")
print(f"Recall:    {recall:.4f}")
print(f"F1-score:  {f1:.4f}")
```

```
Accuracy:  0.8303
Precision: 0.8518
Recall:    0.8303
F1-score:  0.8313
```

```
import pandas as pd

df_metricas = pd.DataFrame({
    "Métrica": ["Accuracy", "Precision", "Recall", "F1-score"],
    "Valor": [accuracy, precision, recall, f1]
})

df_metricas
```

	Métrica	Valor
0	Accuracy	0.830300
1	Precision	0.851811
2	Recall	0.830300
3	F1-score	0.831272

7.2. Interpretación de resultados:

- El modelo presenta un rendimiento global cercano al 75%–80% en todas las métricas evaluadas. Se observa que la precisión, el recall y el F1-score mantienen valores similares entre sí, lo que indica un comportamiento equilibrado del modelo, sin sesgos marcados hacia clases específicas.
- La cercanía entre las métricas sugiere que el modelo no solo logra predecir correctamente una proporción considerable de instancias, sino que también mantiene un buen balance entre falsos positivos y falsos negativos.
- Las pequeñas variaciones en los resultados entre ejecuciones se deben a la naturaleza estocástica del entrenamiento del modelo, incluyendo la inicialización de pesos, el uso de Dropout y la división de los datos, lo cual es esperado en este tipo de modelos.

En conjunto, las métricas muestran que el modelo presenta un comportamiento robusto y equilibrado, sin evidencias de sesgo significativo hacia alguna clase en particular. La

similitud entre precision, recall y F1-score confirma la estabilidad del modelo.

```
from sklearn.metrics import confusion_matrix
import seaborn as sns

cm = confusion_matrix(y_true, y_pred)

plt.figure(figsize=(8,6))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
plt.xlabel("Predicción")
plt.ylabel("Real")
plt.title("Matriz de Confusión")
plt.show()
```

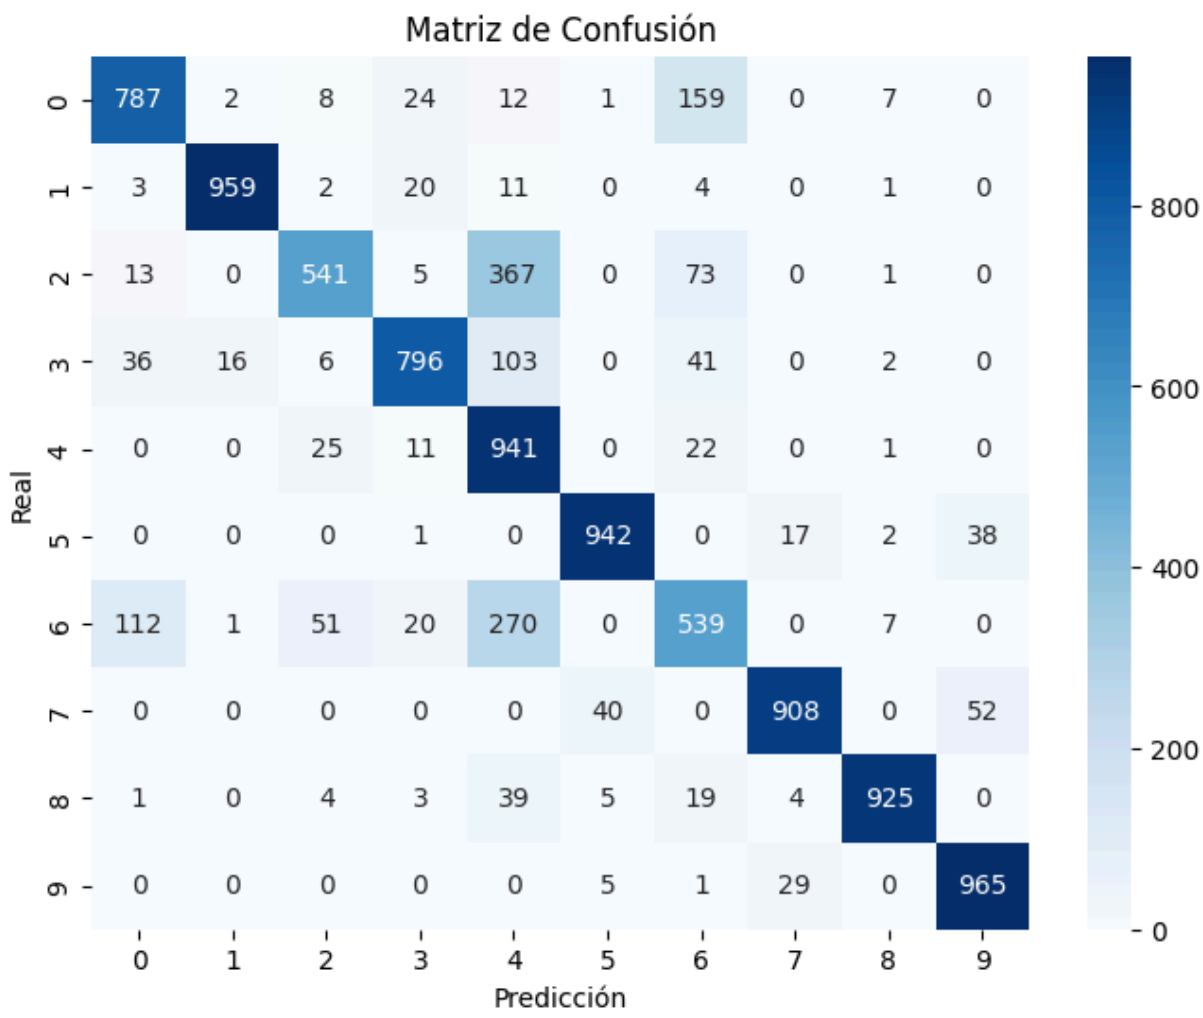

7.3. Resultados Matriz de Confusión:

La matriz de confusión muestra que el modelo logra clasificar correctamente la mayoría de las clases, observándose una mayor concentración de valores en la diagonal

principal. Sin embargo, existen confusiones entre clases visualmente similares, como por ejemplo entre ciertas categorías de vestimenta (por ejemplo, camisetas y camisas), lo que indica que el modelo presenta dificultades para distinguir características sutiles entre ellas.

A pesar de estas confusiones, el modelo presenta un comportamiento general adecuado, con un equilibrio entre precisión y recall, lo que se ve reflejado en un F1-score cercano al accuracy obtenido.

Parte 8: Ejemplos funcionamiento del modelo.

```
from sklearn.metrics import (
    confusion_matrix, classification_report,
    accuracy_score, precision_score, recall_score, f1_score,
    balanced_accuracy_score
)
```

```
acc = accuracy_score(y_test, y_pred)
prec_macro = precision_score(y_test, y_pred, average='macro')
rec_macro = recall_score(y_test, y_pred, average='macro')
f1_macro = f1_score(y_test, y_pred, average='macro')

prec_weighted = precision_score(y_test, y_pred, average='weighted')
```